ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KĨ THUẬT MÁY TÍNH

KHAI PHÁ DỮ LIỆU - CO3029
BÁO CÁO BÀI TẬP LỚN

"Vietnamese News Classification"

GVHD: Đỗ Thanh Thái

Nhóm: 12

Sinh viên thực hiện: Võ Công Đăng Khôi 2311708
Nguyễn Sĩ Hoàng Khang 2311428
Nguyễn Thị Cẩm Vân 2313870

Tp. Hồ Chí Minh, ngày 16 tháng 11 năm 2025

Mục lục

1 Tổng quan đề tài **2**

2 Chọn dữ liệu - Data selection **2**

3 Tiền xử lí dữ liệu - Data preprocessing **3**

3.1 EDA ban đầu - Raw data exploration 3

3.2 Tiền xử lí dữ liệu - Data preprocessing 4

3.3 EDA sau tiền xử lí - Clean data exploration 5

4 Biểu diễn dữ liệu - Vectorization **9**

5 Huấn luyện mô hình - Modeling **11**

5.1 Naive Bayes 11

5.2 Support Vector Machine - SVM 12

5.3 Artificial Neural Network - ANN 13

6 Đánh giá mô hình - Evaluation **14**

7 Kết luận & Hướng phát triển **16**

7.1 Kết luận 16

7.2 Hướng phát triển 16

Tài liệu tham khảo

Tài liệu tham khảo chính

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- GecksforGecks (2025). *Naive Bayes vs. SVM for Text Classification*. Truy cập từ https://www.geeksforgeeks.org/machine-learning/naive-bayes-vs-svm-for-te

Bộ dữ liệu sử dụng

- Bộ dữ liệu Vietnamese Online News Dataset: https://www.kaggle.com/datasets/haitranquangofficial/vietnamese-online-news-dataset
- Tập dữ liệu tải về tại Google Drive: https://drive.google.com/drive/folders/1W2hG98_zCBePrVBbGFBjO82IdrbSQZOf?usp=drive_link

Mã nguồn và mô hình

- Mã nguồn và file huấn luyện: https://github.com/van080105/VNese-Classification
- File mô hình và báo cáo chi tiết: https://drive.google.com/drive/folders/1W2hG98_zCBePrVBbGFBjO82IdrbSQZOf?usp=drive_link

1 Tổng quan đề tài

Đề tài: Vietnamese News Classification

Mục đích chính: Xây dựng mô hình học máy để tự động phân loại bài báo tiếng Việt theo chủ đề. Cụ thể hơn:

- Khi nhập vào một bài báo hoặc tin tức mới, hệ thống sẽ tự động dự đoán chủ đề của bài báo đó (ví dụ: thể thao, kinh tế, giáo dục, giải trí, pháp luật...).
- Mục tiêu cuối cùng là giúp tự động hóa việc tổ chức và xử lý thông tin báo chí.

Mục tiêu kĩ thuật:

- Làm sạch và chuẩn hóa dữ liệu tiếng việt.
- Biểu diễn văn bản bằng TF-IDF.
- Huấn luyện và so sánh 3 mô hình: Naive Bayes, SVM, CNN.
- Đánh giá hiệu quả mô hình: so sánh Accuracy, F1-score, thời gian train, confusion matrix,...
- Trực quan hóa và đưa ra kết luận.

2 Chọn dữ liệu - Data selection

Nguồn từ Kaggle: https://www.kaggle.com/datasets/haitranquangofficial/vietnamese-online-news-dataset

Thời gian thu thập: 15/10/2025

Mô tả dữ liệu: Bộ dữ liệu Vietnamese Online News Dataset được tổng hợp từ 25 trang báo điện tử phổ biến nhất tại Việt Nam trong tháng 7 năm 2022. Dữ

liệu bao gồm các bài viết trực tuyến thuộc nhiều chủ đề khác nhau, được thu thập nhằm phục vụ cho các bài toán Xử lý Ngôn ngữ Tự nhiên (NLP) bằng tiếng Việt như phân loại văn bản, phân tích cảm xúc, tóm tắt tin tức, hoặc mô hình ngôn ngữ.

Trong bối cảnh báo chí trực tuyến ngày càng trở nên phổ biến nhờ khả năng tiếp cận nhanh chóng và hầu như miễn phí, các nội dung tin tức có ảnh hưởng lớn đến tư duy và hành vi của cộng đồng. Việc nghiên cứu, phân tích và xử lý dữ liệu báo chí không chỉ có ý nghĩa trong lĩnh vực công nghệ mà còn giúp hiểu rõ hơn về xu hướng xã hội, mối quan tâm của công chúng, và các chuẩn mực văn hóa được thể hiện qua ngôn từ báo chí.

Tại Việt Nam, dù báo chí trực tuyến từng vấp phải một số chỉ trích trong những năm gần đây, nhưng vẫn duy trì tỷ lệ truy cập cao (khoảng 27%), khẳng định vai trò quan trọng của nó trong hệ sinh thái truyền thông hiện đại.

	Unnamed: 0	id	author	content	picture_count	processed	source	title	topic	url	crawled_at
0	0	218270	NaN	Chiều 31/7, Công an tỉnh Thừa Thiên - Huế đã c...	3	0	docbao.vn	Tên cướp tiệm vàng tại Huế là đại uý công an, ...	Pháp luật	https://docbao.vn/phap-luat/ten-cuop-tiem-vang...	2022-08-01 09:09:22.817308
1	1	218269	(Nguồn: Sina)	Gần đây, Thứ trưởng Bộ Phát triển Kỹ thuật số,...	1	0	vtc.vn	Bỏ qua mạng 5G, Nga tiến thẳng từ 4G lên 6G	Sống kết nối	https://vtc.vn/bo-qua-mang-5g-nga-tien-thang-t...	2022-08-01 09:09:21.181469
2	2	218268	Hồ Sỹ Anh	Kết quả thi tốt nghiệp THPT năm 2022 cho thấy ...	3	0	thanhnien.vn	Địa phương nào đứng đầu cả nước tổng điểm 3 mô...	Giáo dục	https://thanhnien.vn/dia-phuong-nao-dung-dau-c...	2022-08-01 09:09:15.311901
3	3	218267	Ngọc Ánh	Thống đốc Kentucky Andy Beshear hôm 31/7 cho h...	1	0	vnexpress	Người chết trong mưa lũ 'nghìn năm có một' ở M...	Thế giới	https://vnexpress.net/nguoi-chet-trong-mua-lu-...	2022-08-01 09:09:02.211498
4	5	218265	NaN	Chia sẻ trên Twitter, thị trường Hanover Belit...	2	0	tuoitre.vn	Đức có thể suy thoái kinh tế năm nay	Thế giới	https://tuoitre.vn/duc-co-the-suy-thoai-kinh-t...	2022-08-01 09:09:01.320653

Hình 1: Dữ liệu sơ bộ

3 Tiền xử lí dữ liệu - Data preprocessing

3.1 EDA ban đầu - Raw data exploration

Tổng quan dữ liệu:

- Số dòng (records): 172,132
- Số cột (features): 11

- Số cột object: 7
- Số cột số: 4

Tổng số bài trùng nộp dung: 26,990
→ Tỉ lệ trùng: 15,59

	Tên cột	Kiểu dữ liệu	Giá trị không null	Giá trị null	Tỷ lệ thiếu (%)
0	Unnamed: 0	int64	173132	0	0.000000
1	id	int64	173132	0	0.000000
2	author	object	137629	35503	20.510000
3	content	object	150246	22886	13.220000
4	picture_count	int64	173132	0	0.000000
5	processed	int64	173132	0	0.000000
6	source	object	173127	5	0.000000
7	title	object	173115	17	0.010000
8	topic	object	129413	43719	25.250000
9	url	object	173132	0	0.000000
10	crawled_at	object	172741	391	0.230000

Hình 2: Thống kê cột trong dataset

Nhận xét: Cột content quan trọng nhất nhưng thiếu nhiều (13,2%), Cột topic thiếu nhiều nhất (25,25%) nên cần được xử lí.

3.2 Tiền xử lí dữ liệu - Data preprocessing

- Giữ lại 3 cột: title, topic, content
- Làm sạch cột
- Xóa dòng trống, duplicate, bài quá ngắn
- Lọc topic nhiều bài ($\geq$ 5000)
- Áp dụng Tokenization & Stopword Removal vào title và content

3.3 EDA sau tiền xử lí - Clean data exploration

Sau khi hoàn thành bước làm sạch, nhóm tiến hành khai phá dữ liệu (EDA) nhằm đánh giá chất lượng dữ liệu mới và so sánh với dữ liệu gốc.

```
Trước xử lý: (173132, 3)
Sau xử lý: (51880, 3)
Giữ lại 29.97% dữ liệu sau làm sạch.
```

Hình 3: Kết quả sau xử lí

Nhận xét: Sau khi xử lý, dữ liệu còn 51,880 dòng, đây là một tập dữ liệu tương đối lớn và đủ tốt để huấn luyện các mô hình phân loại văn bản (text classification). Việc giảm từ 173k+ xuống 51k cho thấy dữ liệu đã được loại bỏ nhiều dòng lỗi, trùng, hoặc không hợp lệ → chất lượng dữ liệu hiện tại cao hơn.

```
Tổng quan sau xử lý:
<class 'pandas.core.frame.DataFrame'>
Index: 51880 entries, 0 to 173130
Data columns (total 3 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   title    51880 non-null  object
 1   content  51880 non-null  object
 2   topic    51880 non-null  object
dtypes: object(3)
memory usage: 1.6+ MB
None

Số dòng còn lại: 51880
Số topic: 7

Phân bố topic:
topic
thế giới      11635
thể thao       9508
pháp luật      7826
thời sự        6657
kinh doanh     6158
giải trí       5060
sức khỏe       5036
Name: count, dtype: int64
```

Hình 4: Tổng quan dữ liệu sau khi xử lí

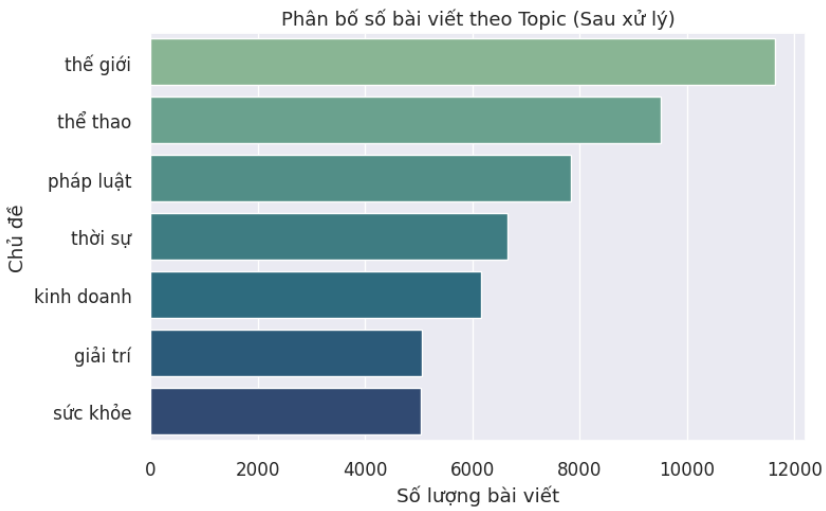

Hình 5: Phân bố số bài viết theo Topic

Nhận xét:

- **Chất lượng dữ liệu:** Tất cả cột đều có số lượng non-null đầy đủ (51,880/51,880) → không còn missing values. Dtype đều là object → phù hợp cho xử lý văn bản.
- **Phân bố topic:** Dataset khá cân bằng, không có topic nào quá thấp ($<$ 5k). Tỷ lệ chênh lệch giữa lớn nhất (11,635) và nhỏ nhất (5,036) $\approx$ 2.3 lần → chưa phải là mất cân bằng nghiêm trọng.
- **Tính đa dạng nội dung:** Các topic bao phủ nhiều lĩnh vực xã hội: thời sự, thế giới, kinh doanh, pháp luật, giải trí, thể thao, sức khỏe. → Điều này tạo dataset đa dạng ngữ nghĩa, thích hợp.

	Trước xử lý	Sau xử lý
Bài trùng lặp	26990	22886
Bài trống	229	0

Hình 6: Chất lượng dữ liệu trước và sau xử lí

Nhận xét:

Số bài trùng lặp giảm đáng kể: Loại bỏ được hơn 4 nghìn bài trùng lặp, tương đương xấp xỉ 15% số bài trùng. → Điều này cho thấy dữ liệu ban đầu có nhiều bài lặp (có thể do crawl từ nhiều nguồn hoặc cùng sự kiện đăng lại). Sau xử lý, vẫn còn 22,886 bài trùng lặp → có thể các bài có title trùng nhưng content khác, hoặc bài viết khác nhau nhưng chung chủ đề được giữ lại. → Điều này có thể chấp nhận được, vì không nhất thiết phải loại 100% duplicates nếu nội dung vẫn mang giá trị.

Số bài trống đã được xử lý hoàn toàn: Làm sạch toàn bộ bài viết trống (content hoặc title rỗng). Đây là dấu hiệu cho thấy quá trình kiểm tra null / blank đầy đủ và chính xác.

Kết luận: Dữ liệu sau xử lý có chất lượng tốt hơn rõ rệt, giảm dữ liệu rác, giảm trùng lặp, đảm bảo đầy đủ nội dung và phù hợp để đưa vào quy trình tiền xử lý NLP hoặc huấn luyện mô hình phân loại.

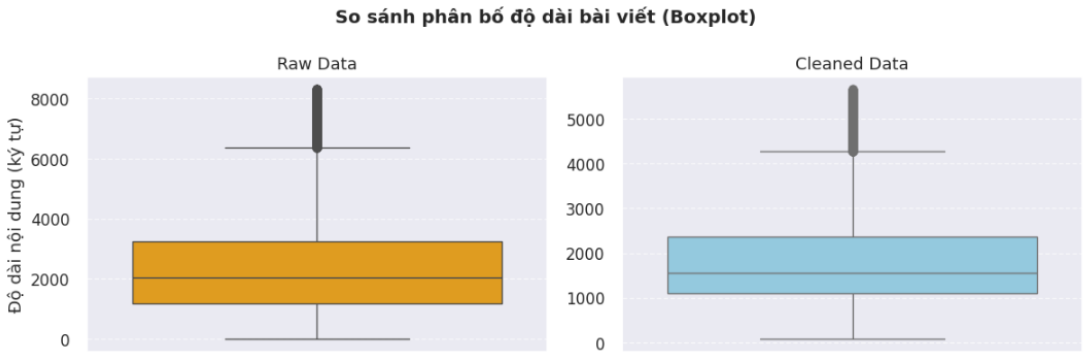

Hình 7: So sánh biểu đồ Boxplot

Nhận xét: Phần lớn outlier đã giảm đáng kể, giới hạn ở 4.500–5.500 ký tự. Median thấp hơn, dữ liệu đã đồng nhất hơn. Boxplot thu gọn lại, độ dài nội dung các bài viết đã ổn định và bớt nhiễu. Phân bố đều và "đẹp" hơn: ít bài quá ngắn hoặc quá dài.

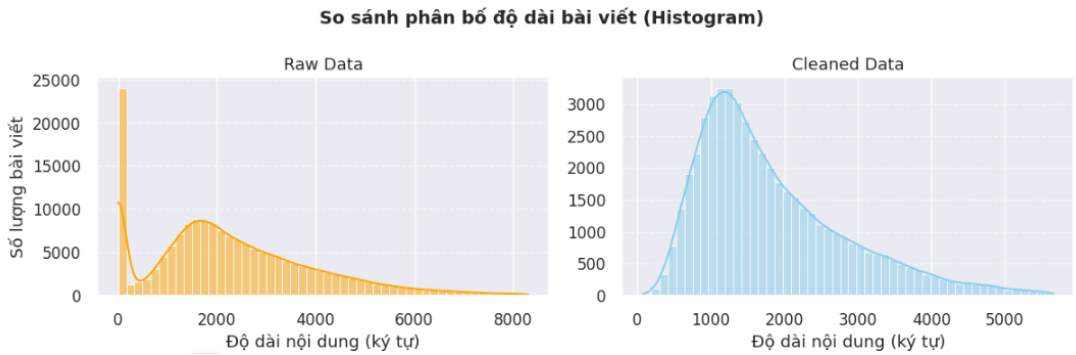

Hình 8: So sánh biểu đồ Histogram

Nhận xét: Biểu đồ trở nên mượt và rõ ràng hơn. Loại bỏ hoàn toàn các bài cực ngắn, không còn cột spike ở mức gần bằng 0 ký tự. Phân bố nghiêng phải (right-skewed) tự nhiên hơn. Nhiều bài trong khoảng 1.000–2.000 ký tự, phù hợp với độ dài tin tức phổ biến. Đuôi phải ngắn lại, không còn bài quá dài bất thường. Sau xử lý, phân bố độ dài nội dung phản ánh đúng đặc trưng của bài báo thực tế: không bài trống, ít bài quá dài, tập trung vào khoảng độ dài tin tức chuẩn (1.000–2.000 ký tự). Dữ liệu sạch hơn, tự nhiên hơn và phù hợp để huấn luyện mô hình.

Hình 9: WordCloud title

Nhận xét: Các từ phổ biến phản ánh đúng đặc trưng báo chí Việt Nam như Tên báo: dân chí, tuổi trẻ online; Địa danh: Việt Nam, Hà Nội; Thể thao: Ronaldo, v-league, ... Tuy nhiên, Title chứa nhiều từ đặc trưng theo tên báo, điều này không giúp phân loại topic.

4 Biểu diễn dữ liệu - Vectorization

Mục đích: Chuyển đổi văn bản thành dạng số để sử dụng trong các mô hình học máy.

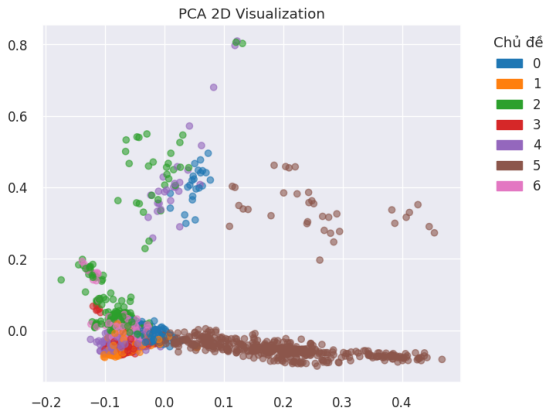

Hình 10: PCA 2D Visualization

Nhận xét: Các điểm dữ liệu của các chủ đề được phân tách nhưng có sự chồng lấn giữa hầu hết các nhóm, chủ đề 6 có sự phân tách rõ ràng. PCA có thể không phân tách rõ rệt các nhóm, đặc biệt trong trường hợp các nhóm dữ liệu có sự tương đồng cao về các đặc trưng.

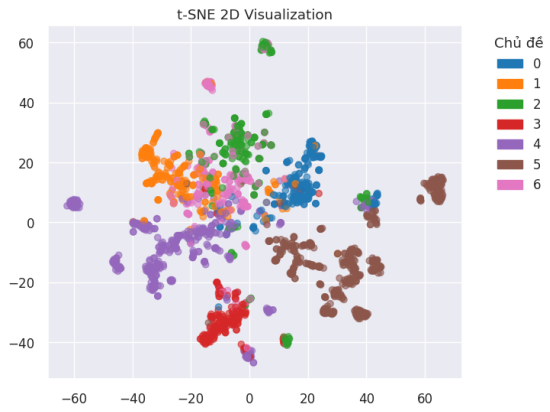

Hình 11: t-SNE 2D Visualization

Nhận xét: Các nhóm chủ đề được phân tách rõ ràng hơn so với PCA. Các điểm

dữ liệu của chủ đề không bị chồng lấn nhiều. t-SNE làm rõ hơn mối quan hệ giữa các nhóm chủ đề và thể hiện sự phân biệt rõ ràng hơn trong không gian 2D.

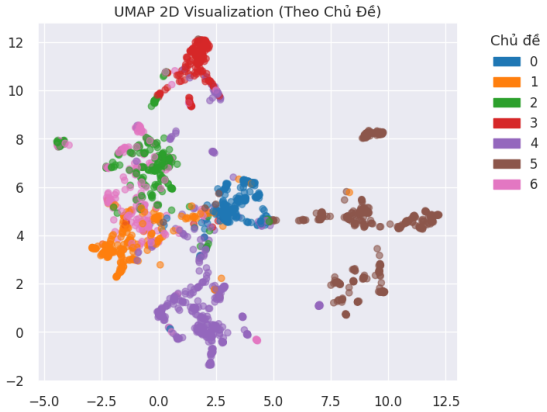

Hình 12: UMAP 2D Visualization (Theo chủ đề)

Nhận xét: Các chủ đề có sự phân tách rõ ràng mà không bị chồng lấn nhau nhiều. UMAP giúp các nhóm dữ liệu có sự phân bổ đồng đều và tương đối cân đối, thể hiện khả năng duy trì các cấu trúc cục bộ của dữ liệu tốt hơn cả t-SNE và PCA.

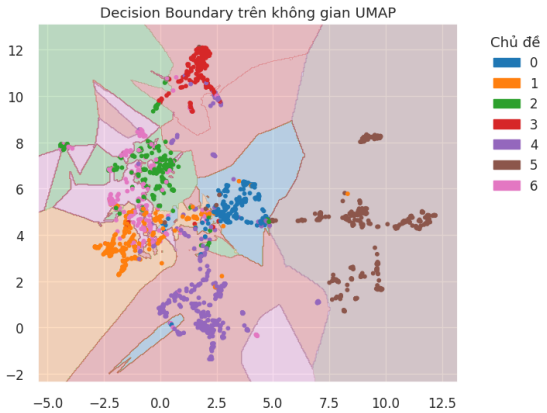

Hình 13: Decision Boundary trên UMAP

Nhận xét: Các chủ đề được phân chia bởi các đường biên quyết định rõ ràng. Các khu vực màu sắc đại diện cho các lớp chủ đề, và mô hình KNN đã sử dụng các đặc trưng của không gian UMAP để phân chia các điểm dữ liệu vào các nhóm chủ đề khác nhau.

5 Huấn luyện mô hình - Modeling

5.1 Naive Bayes

```
NB alpha=0.1 → accuracy=0.8928
NB alpha=0.5 → accuracy=0.8919
NB alpha=1.0 → accuracy=0.8931

[Naive Bayes] Best alpha=1.0, Accuracy=0.8931

Báo cáo Naive Bayes:
              precision    recall  f1-score   support

    giải trí       0.87      0.97      0.92      1012
   kinh doanh      0.89      0.88      0.88      1232
    pháp luật      0.79      0.95      0.86      1565
     sức khỏe      0.89      0.91      0.90      1007
     thế giới      0.94      0.92      0.93      2327
     thể thao      1.00      0.98      0.99      1902
      thời sự      0.80      0.62      0.70      1331

     accuracy                           0.89     10376
    macro avg      0.88      0.89      0.88     10376
 weighted avg      0.89      0.89      0.89     10376
```

Hình 14: Kết quả huấn luyện mô hình NB

Nhận xét: Mô hình có độ chính xác khá cao là 0.8933. Hiệu suất mạnh ở hầu hết các chủ đề (nhất là thể thao), nhưng một số chủ đề còn thấp, đặc biệt là "thời sự"và “pháp luật”. Việc điều chỉnh thêm mô hình như tăng cường dữ liệu hoặc turning tham số có thể giúp cải thiện hiệu suất, đặc biệt là đối với các hạng mục có recall và F1-score thấp.

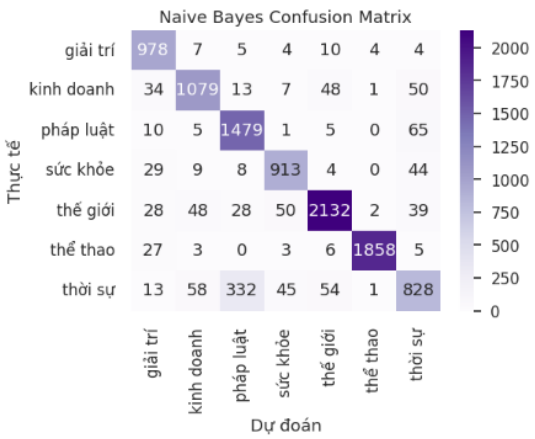

Hình 15: NB Confusion Matrix

5.2 Support Vector Machine - SVM

```
[SVM Linear] Accuracy=0.9396

Báo cáo SVM:
              precision    recall  f1-score   support

   giải trí       0.98      0.97      0.97      1012
  kinh doanh      0.93      0.92      0.93      1232
   pháp luật      0.90      0.94      0.92      1565
    sức khỏe      0.94      0.96      0.95      1007
    thế giới      0.95      0.97      0.96      2327
    thể thao      0.99      1.00      0.99      1902
     thời sự      0.87      0.79      0.83      1331

    accuracy                           0.94     10376
   macro avg      0.94      0.93      0.94     10376
weighted avg      0.94      0.94      0.94     10376
```

Hình 16: Kết quả huấn luyện mô hình SVM

Nhận xét: Mô hình SVM đạt hiệu quả cao trong việc phân loại văn bản theo các chủ đề với độ chính xác tổng thể tốt. Có sự khác biệt giữa các chủ đề, với một số chủ đề như "thời sự"có độ chính xác và khả năng nhận diện chưa cao. Cải thiện bằng việc điều chỉnh mô hình hoặc thêm dữ liệu huấn luyện cho các chủ đề ít gặp.

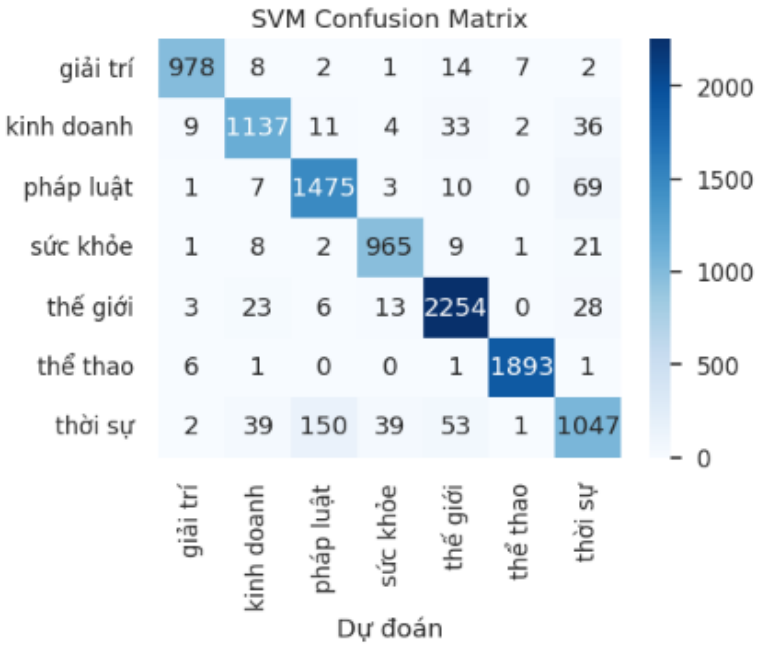

Hình 17: SVM Confusion Matrix

5.3 Artificial Neural Network - ANN

```
[ANN] Accuracy=0.9307

Báo cáo ANN:
              precision    recall  f1-score   support

   giải trí       0.97      0.97      0.97      1012
  kinh doanh      0.93      0.92      0.92      1232
   pháp luật      0.87      0.94      0.90      1565
    sức khỏe      0.94      0.94      0.94      1007
    thế giới      0.95      0.96      0.96      2327
    thể thao      0.99      0.99      0.99      1902
     thời sự      0.84      0.76      0.80      1331

    accuracy                           0.93     10376
   macro avg      0.93      0.93      0.93     10376
weighted avg      0.93      0.93      0.93     10376
```

Hình 18: Kết quả huấn luyện mô hình ANN

Nhận xét: Mô hình ANN đạt độ chính xác cao (> 0.9) Tổng thể, ANN thể hiện khả năng học đặc trưng tốt và ổn định, thích hợp cho bài toán phân loại văn bản tiếng Việt. Tăng số lớp ẩn hoặc thử kiến trúc Deep ANN / LSTM để cải thiện khả năng nắm bắt ngữ cảnh. Sử dụng pretrained word embeddings (Word2Vec, FastText) thay cho embedding ngẫu nhiên. Điều chỉnh Dropout và batch size để tăng độ tổng quát của mô hình.

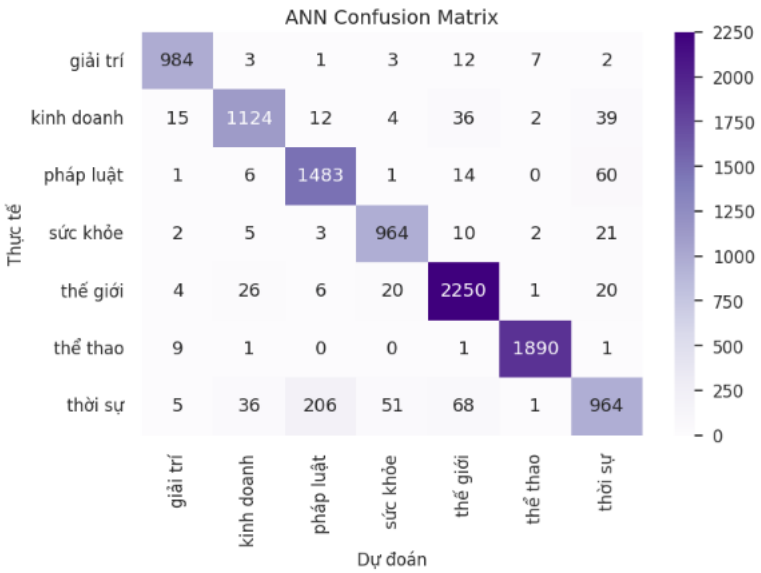

Hình 19: ANN Confusion Matrix

6 Đánh giá mô hình - Evaluation

Bảng dưới đây trình bày sự khác biệt giữa ba mô hình được sử dụng trong đề tài: Naive Bayes, Support Vector Machine (SVM) và Artificial Neural Network (ANN). Các tiêu chí được phân tích bao gồm: ưu điểm, hiệu suất, hiệu năng, khả năng mở rộng, khả năng diễn giải và hạn chế của từng mô hình.

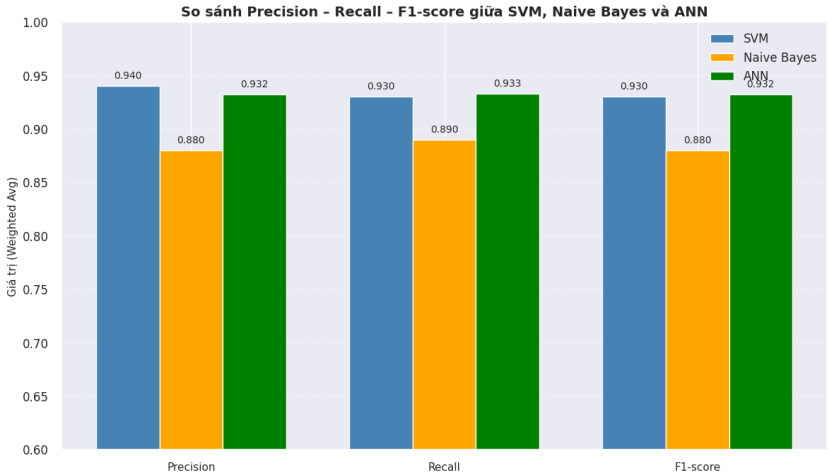

Hình 20: So sánh Precios - Recall - F1-score giữa NB, SVM, ANN

Nhận xét:

- **Naive Bayes** có hiệu suất thấp nhất Các chỉ số Precision, Recall và F1 đều thấp hơn hai mô hình còn lại. Tuy nhiên Naive Bayes vẫn cho kết quả nhanh, phù hợp khi tài nguyên hạn chế.
- **Support Vector Machine (SVM)** có hiệu năng ổn định và vượt trội hơn Naive Bayes SVM có chỉ số Precision – Recall – F1 cao vượt trội Naive Bayes ở tất cả tiêu chí. Biên phân cách của SVM giúp mô hình hoạt động ổn định trên dữ liệu có số chiều lớn, như bài toán phân loại văn bản.
- **Artificial Neural Network (ANN)** đạt hiệu năng cao ANN có Precision, Recall và F1-score đều cao xấp xỉ SVM. Điều này cho thấy ANN cũng có

khả năng học tốt các đặc trưng ngữ nghĩa trong văn bản nhờ kiến trúc nhiều tầng và khả năng học phi tuyến tính.

Tiêu chí	**Naive Bayes**	**Support Vector Machine (SVM)**	**Artificial Neural Network (ANN)**
Ưu điểm	Đơn giản, dễ triển khai; tính toán nhanh; hoạt động tốt với dữ liệu nhỏ.	Hiệu quả trong không gian đặc trưng lớn; mạnh mẽ trước overfitting; linh hoạt với nhiều loại kernel.	Học quan hệ phi tuyến mạnh; bắt đặc trưng ngữ nghĩa tốt; hiệu suất cao trên dữ liệu lớn.
Hiệu suất (Efficiency)	Huấn luyện và dự đoán nhanh.	Huấn luyện chậm, tốn tài nguyên nhưng dự đoán nhanh.	Huấn luyện chậm do nhiều tham số nhưng ổn định nhờ batch training.
Hiệu năng (Performance)	Tốt cho bài toán đơn giản; xử lý tốt dữ liệu nhiễu.	Hiệu quả cao trong bài toán phức tạp nhưng nhạy cảm với nhiễu.	Độ chính xác cao; học được quan hệ phi tuyến phức tạp.
Khả năng mở rộng (Scalability)	Mở rộng tốt khi số lượng đặc trưng lớn.	Kém mở rộng khi dữ liệu rất lớn.	Mở rộng linh hoạt bằng cách tăng tầng hoặc neuron; cần phần cứng mạnh như GPU.
Khả năng diễn giải (Interpretability)	Dễ hiểu và cung cấp xác suất từng lớp.	Khó diễn giải do biên quyết định phức tạp.	Khó giải thích nhưng có thể dùng SHAP/LIME.
Độ bền vững (Robustness)	Nhạy cảm với giả định độc lập đặc trưng.	Mạnh mẽ trước nhiễu và ngoại lệ.	Ổn định hơn nếu dùng dropout/ regularization; có thể overfit khi dữ liệu nhỏ.
Hạn chế	Giả định độc lập khiến kết quả thiếu chính xác.	Huấn luyện tốn tài nguyên, phụ thuộc kernel.	Khó huấn luyện, dễ overfit, cần tinh chỉnh nhiều tham số.

7 Kết luận & Hướng phát triển

7.1 Kết luận

Qua quá trình xây dựng, huấn luyện và đánh giá ba mô hình phân loại văn bản tiếng Việt, có thể rút ra một số kết luận chính như sau:

- **Naive Bayes** đạt tốc độ huấn luyện rất nhanh và hiệu năng tốt đối với bài toán đơn giản hoặc dữ liệu ít. Tuy nhiên, độ chính xác không cao bằng các mô hình hiện đại do giả định độc lập giữa các đặc trưng.
- **Support Vector Machine (SVM)** đạt độ chính xác cao hơn NB. Mô hình hoạt động tốt với dữ liệu dạng TF-IDF và cho biên quyết định rõ ràng trong không gian đặc trưng lớn.
- **Artificial Neural Network (ANN)** cho kết quả cao nhất trong các mô hình thử nghiệm. Nhờ khả năng học biểu diễn từ Word Embedding, ANN nắm bắt tốt ngữ nghĩa và các quan hệ phi tuyến giữa các từ trong văn bản. Tuy nhiên, nó đòi hỏi thời gian huấn luyện lâu hơn và tài nguyên tính toán mạnh hơn (CPU/GPU).

Nhìn chung, SVM là lựa chọn mạnh mẽ và ổn định đối với bài toán truyền thống. Trong khi đó, ANN thể hiện tiềm năng vượt trội của học sâu (Deep Learning) trong phân loại văn bản tiếng Việt.

7.2 Hướng phát triển

Trong tương lai, hệ thống có thể được cải thiện đáng kể thông qua việc ứng dụng các phương pháp biểu diễn ngữ nghĩa hiện đại. Thay vì sử dụng các kỹ thuật truyền thống như TF-IDF, mô hình có thể khai thác các **pre-trained embeddings** như **FastText, Word2Vec** hoặc đặc biệt là các mô hình mạnh dành cho tiếng Việt như **PhoBERT**. Các mô hình này cung cấp vector biểu diễn giàu ngữ nghĩa, giúp

mô hình phân loại hiểu sâu hơn ngữ cảnh và mối quan hệ giữa các từ, từ đó nâng cao độ chính xác của hệ thống.

Bên cạnh đó, việc **áp dụng các mô hình học sâu tiên tiến** là một hướng phát triển quan trọng. Các kiến trúc như **TextCNN, LSTM, BiLSTM** hoặc **VDCNN** có khả năng học sâu cấu trúc câu và ngôn ngữ theo trình tự thời gian, phù hợp với dữ liệu văn bản tiếng Việt vốn giàu tính ngữ cảnh. So với các mô hình truyền thống, các kiến trúc deep learning thường mang lại hiệu suất tốt hơn và khả năng tổng quát hóa cao hơn, đặc biệt khi kết hợp với các vector từ được huấn luyện trước.

Để đạt hiệu năng tối ưu, một hướng đi khác là tiếp tục **tối ưu hyperparameters** của mô hình. Việc điều chỉnh có kiểm soát các tham số như learning rate, số tầng ẩn, số lượng filter hoặc kích thước batch có thể tạo ra sự cải thiện đáng kể về hiệu quả dự đoán. Các phương pháp như **Grid Search, Random Search** hoặc **Bayesian Optimization** có thể được áp dụng để tìm ra cấu hình tốt nhất cho mô hình.

Cuối cùng, dự án có tiềm năng lớn để **triển khai thành ứng dụng thực tế**. Việc xây dựng một API hoặc giao diện web cho phép người dùng nhập văn bản và nhận kết quả dự đoán chủ đề theo thời gian thực không chỉ mở rộng khả năng ứng dụng mà còn giúp đánh giá mô hình trong môi trường sử dụng thật. Điều này giúp hệ thống trở nên hữu ích hơn trong các bài toán phân loại tin tức, bộ lọc nội dung, gợi ý bài viết và hỗ trợ tổng hợp thông tin.